Kochbuch FoBa

Wie ein gieriges Verfahren seine eigenen Fehlgriffe wieder loswird, und warum es dabei nicht im Kreis läuft.

Reihe: Weak Form → FROLS → FoBa → Trajektorien-Check. Setzt FROLS voraus: den normierten Gewinn eines Terms.

Was der Name bedeutet

Forward-**Ba**ckward, genauer „adaptive forward-backward greedy algorithm“ von Tong Zhang (NIPS 2008, IEEE Trans. Inf. Theory 2011). Ein Vorwärtsschritt fügt einen Term hinzu, wie FROLS. Danach folgen null oder mehr Rückwärtsschritte, die Terme wieder entfernen, wenn sie es nicht mehr wert sind.

Die Idee ist alt (schrittweise Regression, Efroymson 1960). Neu war bei Zhang die **Regel, wann** rückwärts entfernt wird. Sie verhindert, dass das Verfahren endlos hinzufügt und entfernt, und mit ihr lässt sich beweisen, dass es unter Bedingungen an die Korrelation der Spalten die wahren Terme findet.

Die Regel in einer Zeile

Der letzte Vorwärtsschritt hat den Gewinn δ gebracht. Ein Term t im Modell kostet beim Entfernen:

```
Kosten(t) = SSE(S ohne t) − SSE(S)          (normiert durch ‖b‖², wie der Gewin

Entferne t,  wenn  Kosten(t) < ν · δ          bei uns ν = 0,5
```

Auf Deutsch: Ein Term fliegt raus, wenn das Modell ohne ihn um weniger als die Hälfte schlechter wird, als der letzte Schritt es verbessert hat. Gibt es mehrere solche Terme, fliegt der billigste zuerst raus, und die Prüfung wird wiederholt, bis keiner mehr unter der Schwelle liegt.

> $\nu = 0{,}5$ ist Zhangs veröffentlichter Standardwert, von uns nicht eingestellt.

Warum es nicht im Kreis läuft

Jeder Vorwärtsschritt senkt den Restfehler um δ. Jede Entfernung danach erhöht ihn um weniger als $\nu \cdot \delta$. Ein Paar aus Hinzufügen und Entfernen senkt den Fehler also netto um mehr als $(1 - \nu) \cdot \delta$. Da der Restfehler nicht unter null fallen kann, kann es nur endlich viele solche Runden geben. Ein Modell, das schon einmal da war, kann nicht wiederkommen.

> Unser Code prüft das zusätzlich: Taucht eine Termmenge zum zweiten Mal auf, bricht er mit der Meldung „Repeated FoBa model“ ab. Das ist in Q4 nie passiert.

Das Rezept, so wie wir es bauen

1 **Vorwärtsschritt (FROLS)**
Den Term mit dem größten normierten Gewinn δ über alle Gleichungen hinzufügen.

2 **Für jeden Term im Modell die Kosten ausrechnen**
In allen Gleichungen, nicht nur in der, die gerade gewachsen ist. Ein neuer Term in Gleichung 1 kann einen Term in Gleichung 1 überflüssig machen; die Kosten in den anderen Gleichungen ändern sich dabei nicht, sie werden aber jedes Mal mitgeprüft.

3 **Den billigsten Term unter der Schwelle entfernen**
Schwelle ist $0{,}5 \cdot \delta$ mit dem δ des *letzten Vorwärtsschritts*. Gibt es keinen, ist der Rückwärtsteil fertig.

4 **Wiederholen bis nichts mehr rausfliegt**
Nach einer Entfernung werden die Kosten neu berechnet, denn ohne den entfernten Term können andere wichtiger oder unwichtiger geworden sein.

5 **Zustand als Kandidat merken, weiter mit Schritt 1**
Jede Termmenge nach dem Rückwärtsteil wird Kandidat für die spätere Auswahl per Simulation.

> Code: `growth_path` in `analysis/scripts/aggregate/build_sideproject_q4_paths.py`, die Schleife mit `backward_checks`.

Durchgerechnet: die logistische Gleichung

Dasselbe Beispiel wie in Kochbuch 2. Wahrheit $\dot{x} = x - x^2$. FROLS hat im ersten Schritt fälschlich cos x gewählt. So geht es weiter:

Schritt	hinzu	Gewinn δ	Schwelle 0,5·δ	entfernt (Kosten)	Modell danach
1	cos x	0,700	0,350	nichts	cos x
2	x^3	0,107	0,054	nichts	x^3, cos x
3	sin x	0,187	0,094	cos x (0,013)	x^3, sin x
4	x^2	0,018	0,0089	x^3 (0,0007)	x^2, sin x
5	x	0,0007	0,00036	sin x ($2 \cdot 10^{-12}$)	**x, x^2**
6	1	$3 \cdot 10^{-11}$	–	nichts	1, x, x^2

Gerechnet mit unserem Code (`build_design`, `WeakFit`, `growth_path`) auf einer selbst integrierten Trajektorie, 512 Punkte, ohne Rauschen.

Was hier passiert:

- **Schritt 3:** sin x und x^3 zusammen erklären fast alles, was cos x erklärt hatte. Ohne cos x wird das Modell nur um 0,013 schlechter, viel weniger als die Schwelle von 0,094. Der erste Fehlgriff ist weg.
- **Schritt 4:** Mit x^2 wird x^3 überflüssig (Kosten 0,0007 gegen Schwelle 0,0089).
- **Schritt 5:** Mit x wird sin x überflüssig. Es kostet nur $2 \cdot 10^{-12}$, weil x und x^2 zusammen die Wahrheit sind. **Die wahre Struktur ist erreicht**, nach fünf Schritten und drei Korrekturen.

- **Ab Schritt 6:** Der Pfad geht weiter, aber die Gewinne sind nur noch Rundungsrauschen (10^{-11}). Er liefert noch zwei, drei Kandidaten mit überflüssigen Termen. Dass am Ende „x, x^2“ gewählt wird, entscheidet das Trajektorien-BIC, nicht FoBa.

Bemerkenswert: Der Gewinn ist *nicht* monoton. Schritt 3 bringt mehr als Schritt 2, weil sin x erst zusammen mit x^3 seine Wirkung entfaltet. Das ist der gemeinsame Refit bei der Arbeit.

Zweites Beispiel: Lotka-Volterra, zwei Gleichungen

Wahrheit: $\dot{x} = x - 0{,}5 \cdot x \cdot y$ und $\dot{y} = -0{,}8 \cdot y + 0{,}4 \cdot x \cdot y$. Katalog: 12 Terme. Der Pfad füllt beide Gleichungen zuerst mit sin- und cos-Paaren, die das periodische Auf und Ab nachahmen. Sobald die wahren Terme kommen, räumt FoBa auf:

Schritt	hinzu	entfernt	Gleichung 1	Gleichung 2
1–4	cos, sin in beiden	—	`sin y, cos y`	`sin x, cos x`
5	`x·y`	—	`sin y, cos y`	`x·y, sin x, cos x`
6	`y`	`sin x, cos x`	`sin y, cos y`	**`y, x·y`**
7	`x·y`	—	`x·y, sin y, cos y`	**`y, x·y`**
8	`x`	`sin y, cos y`	**`x, x·y`**	**`y, x·y`**

Nach acht Schritten steht die Wahrheit da, mit vier Fehlgriffen, die alle wieder entfernt wurden. Danach wächst der Pfad bis zum Deckel von 6 Termen weiter (19 Kandidaten insgesamt), mit Gewinnen um 10^{-10}.

Fallstricke

WAS FOBA NICHT KANN

- **Es entfernt nur, was ersetzt wurde.** Ein falscher Term fliegt erst raus, wenn andere Terme seine Arbeit übernehmen. Kommt der passende wahre Term nie an die Reihe, bleibt der falsche drin.

- **Die Schwelle hängt am letzten Schritt.** Ist der letzte Gewinn groß, wird großzügig entfernt; ist er klein, kaum. Unter Rauschen sind späte Gewinne Rauschen, die Schwelle wird winzig, und es fliegt praktisch nichts mehr raus.
- **Kein Stoppsignal.** Wie FROLS sagt FoBa nicht, wann das Modell fertig ist. Zhangs Original stoppt, wenn der Gewinn unter eine Schwelle ε fällt. Wir haben bewusst kein ε, sondern nehmen alle Zwischenstände als Kandidaten und lassen die Simulation entscheiden.
- **Die Garantien gelten für lineare Regression mit nicht zu stark korrelierten Spalten.** Unser Katalog ist auf einer Trajektorie stark korreliert. Die Beispiele zeigen, dass es trotzdem funktioniert; ein Beweis ist das nicht.

Was man daraus mitnimmt

KURZ

FoBa ist das Radiergummi, das EvoGrow fehlt. In EvoGrow kann ein falscher Term eine Linie nie mehr verlassen; hier fliegt er raus, sobald andere Terme ihn ersetzen. Die Regel „entfernen, wenn es weniger kostet als die Hälfte des letzten Gewinns“ ist einfach, garantiert, dass nichts im Kreis läuft, und hat einen veröffentlichten Standardwert. Wie viele Terme das Modell am Ende hat, entscheidet nicht FoBa, sondern die Simulation.

Literatur

Aus dem Gedächtnis, noch nicht online geprüft. Mit (prüfen) markiert, wo die bibliografischen Angaben unsicher sind.

- Efroymson 1960, „Multiple regression analysis“, in Ralston & Wilf (Hrsg.), Mathematical Methods for Digital Computers. Klassische schrittweise Regression.
- Zhang 2009, „Adaptive forward-backward greedy algorithm for sparse learning with linear models“, Advances in NIPS 21 (Konferenz 2008).
- Zhang 2011, „Adaptive forward-backward greedy algorithm for learning sparse representations“, IEEE Trans. Inf. Theory 57(7) (prüfen). Journalfassung mit den Garantien.

- Liu, Ye & Fujimaki 2014, ICML (prüfen). FoBa für allgemeine glatte konvexe Verluste.
- Jalali, Johnson & Ravikumar 2011, NIPS (prüfen). FoBa für Graphenstrukturen.
- Boninsegna, Nüske & Clementi 2018, J. Chem. Phys. 148 (prüfen). SSR, schrittweise Rückwärtselimination im SINDy-Umfeld.