Kochbuch Trajektorien-Check

Wie aus einem Pfad voller Kandidaten am Ende genau ein Modell wird: einmal richtig fitten, simulieren und per BIC die Größe wählen.

Reihe: Weak Form → FROLS → FoBa → Trajektorien-Check. Setzt voraus: Der Pfad aus FROLS und FoBa liefert eine Liste von Kandidaten, jeder mit Koeffizienten aus der schwachen Form.

Warum dieser Schritt das Ergebnis trägt

Nach FoBa haben wir pro Einheit eine Handvoll bis rund zwanzig Kandidaten, vom 1-Term-Modell bis zum Deckel. Einer davon muss gewählt werden. Das Naheliegende wäre, im schwachen Raum zu bleiben: Restfehler plus Strafe pro Term, das „schwache BIC“. Q4 hat beide Wege verglichen:

Struktur exakt (geprunt)	schwaches BIC (a)	Trajektorien-BIC (c)
dim 1 (22 Einheiten)	12/22	**18/22**
dim 2 (20 Einheiten)	8/20	**18/20**
dim 3 fittbar (4 Einheiten)	1/4	**3/4**

Das schwache BIC wählt im Median 4 Terme zu viel. Das Trajektorien-BIC trifft die wahre Größe in 35 von 46 Einheiten exakt. **Die Simulation ist also keine Kosmetik. Sie ist der Teil, der aus einer guten Kandidatenliste ein richtiges Modell macht.**

> Warum der schwache Raum überanpasst, ist nicht gemessen. Die plausibelste Erklärung steht im Kochbuch Weak Form: 2.529 stark überlappende Fenster werden wie 2.529 unabhängige Beobachtungen gezählt. Dazu kommt: Ein kleiner Fehler in $\dot{x}$ bleibt im schwachen Raum klein, summiert sich beim Simulieren aber über die ganze Trajektorie auf. Die Simulation bestraft genau die Terme, die nur lokal passen.

Das Rezept, so wie wir es bauen

1 Startwert aus der schwachen Form nehmen

Jeder Kandidat bringt seine schwachen Koeffizienten mit (Kochbuch Weak Form, Schritt 6). Bei sauberen Daten sind sie schon sehr nah am Optimum.

> Das war Q3: Auf der wahren Struktur erreicht dieser eine Start $R^2 > 0{,}9$ in 22/22 (dim 1) und 20/20 (dim 2). Zehn Zufallsstarts schaffen auf dim 2 nur 39/60, bei rund dreihundertfach höheren Kosten.

2 Einmal mit BFGS im Trajektorienraum fitten

Verlust ist der mittlere quadratische Fehler zwischen simuliertem Modell und Messdaten:

```
MSE(c) = Mittel über alle Messpunkte und Variablen von (x_sim(tᵢ; c)
```

Simuliert wird mit Tsit5 ab dem **ersten Messpunkt** als Anfangswert. BFGS ist derselbe Optimierer wie in EvoGrow (Optimization.jl mit Optim.jl), mit denselben Einstellungen:

- Gradient per **finiten Differenzen**: Jeder Gradient kostet mehrere Simulationen.
- Höchstens 200 Iterationen und höchstens **20.000 Loss-Evaluationen**.
- Jeder Koeffizient wird vor der Simulation auf **[−10, 10]** geklemmt.
- **Genau ein Versuch** (`max_fit_attempts = 1`), kein Neustart bei Misserfolg.

> Code: `q4_fit` in `studies/regression/sideproject_q4_path_fits.jl`. Es ruft `fit_parameters` aus `src/optimize/bfgs.jl` mit `build_reference_optimizer(max_fit_attempts = 1)` aus `run_regression.jl`.

3 Kaputte Fits aussortieren

Bricht die Simulation ab oder explodiert sie, gibt der Fit den Platzhalter-Verlust 10^6 zurück, den „Sentinel“. Solche Kandidaten und divergierte Simulationen werden bei der Auswahl nie genommen.

4 Trajektorien-BIC ausrechnen

```
BIC = N · log(MSE) + k · log(N)
```

```
N = Messpunkte × Dimension   (dim 1: 512,  dim 2: 1.024)
```

Der erste Teil belohnt einen guten Fit, denn der Logarithmus eines kleinen MSE ist stark negativ. Der zweite bestraft jeden Term mit log(N), also etwa 6,2 Punkten (dim 1) bzw. 6,9 Punkten (dim 2). Kleiner ist besser.

> Ein zusätzlicher Term lohnt sich also schon, wenn er den MSE um mehr als den Faktor exp(log(N)/N) senkt, bei dim 1 um mehr als etwa 1,2 %. Das ist eine sehr niedrige Hürde, und das wird gleich wichtig.

5 **Den Kandidaten mit dem kleinsten BIC servieren**

Kein Parameter, keine Schwelle. Danach wird nur noch für die Auswertung gerechnet: Pruning-Regel für den Strukturvergleich, Rekonstruktion auf der Trainingstrajektorie, Generalisierung von der anderen Anfangsbedingung aus.

> Code: Auswahlregel in `analysis/scripts/aggregate/aggregate_sideproject_q4.py`.

Fall 1: SIR-Modell, richtig gewählt, aber knapp

System 31, Anfangsbedingung 1. Wahrheit: $\dot{x} = -c_0 \cdot x \cdot y$, $\dot{y} = c_0 \cdot x \cdot y - c_1 \cdot y$. Auszug aus den echten Q4-Kandidaten:

Kandidat	Gleichung 1	Gleichung 2	k	MSE	BIC
1	x·y	–	1	2,5	952
2	x·y	x·y	2	1,5	434
3	x·y	y, x·y	3	$1{,}49 \cdot 10^{-13}$	**−30.223**
4	x·y	y, x·y, sin x	4	$1{,}54 \cdot 10^{-13}$	−30.180
5	x·y, sin x	y, x·y, sin x	5	$1{,}47 \cdot 10^{-13}$	−30.220
12	6 Terme	6 Terme	12	$4{,}2 \cdot 10^{-10}$	−22.037

Die Wahrheit gewinnt. Aber Kandidat 5 hat zwei überflüssige Terme und liegt nur **3 BIC-Punkte** dahinter, weil sein MSE minimal kleiner ist als der der Wahrheit. Diese

Unterschiede sind kein Signal mehr, sondern die Rechengenauigkeit des Integrators. Das schwache BIC hätte übrigens Kandidat 12 genommen, das größte Modell.

Fall 2: kritisches Abbremsen, Gleichstand am Boden

System 11, Anfangsbedingung 1. Wahrheit: $\dot{x} = -x^3$, ein einziger Term.

Kandidat	Terme	MSE	BIC	roh exakt	geprunt exakt
1	x^3	$4{,}54 \cdot 10^{-15}$	−16.903	ja	ja
2	x^2, x^3	$4{,}28 \cdot 10^{-15}$	−16.927	nein	ja
3	x^2, x^3, sin x	$4{,}35 \cdot 10^{-15}$	−16.913	nein	ja
7	alle 6	$1{,}1 \cdot 10^{-9}$	−10.517	nein	nein

Hier gewinnt **nicht** die Wahrheit, sondern Kandidat 2 mit einem überflüssigen x^2. Sein MSE ist um 6 % kleiner, mehr als die 1,2 %-Hürde. Gezählt wird der Fall trotzdem als Treffer, weil die Pruning-Regel das winzige x^2 wegschneidet. Roh ist er falsch.

Das ist die Warnung aus der Literaturprüfung: **Auf sauberen Daten ist log(MSE) vom Integrator-Boden bestimmt.** Alle Modelle, die den Boden erreichen, sind praktisch gleich gut, und welches gewinnt, entscheidet Rundungsrauschen. Die Strafe pro Term ist zu klein, um das zuverlässig zu trennen.

Fall 3: Lotka-Volterra-Konkurrenz, die Wahrheit ist gar nicht im Topf

System 26, Anfangsbedingung 1. Wahrheit: drei Terme pro Gleichung, in Gleichung 2 unter anderem y und y^2. Der Pfad hat 15 Kandidaten, aber **keiner davon enthält y oder y^2 in Gleichung 2**. FROLS und FoBa haben sie nie gewählt.

Der Trajektorien-Check wählt dann das Modell, das die Trainingstrajektorie am besten nachahmt: Kandidat 15 mit 12 Termen und einer Rekonstruktion von $R^2 = 0{,}9999$. Von der anderen Anfangsbedingung aus divergiert genau dieses Modell (Generalisierung $R^2 = -3{,}8$). Unterwegs gab es außerdem einen Sentinel-Fit (Verlust 10^6, korrekt aussortiert) und vier Fits, die das Budget von 20.000 Loss-Evaluationen ausgeschöpft haben.

> Lektion: Der Trajektorien-Check kann nur unter den Kandidaten wählen, die der Pfad liefert. Fehlt die Wahrheit, findet er das beste falsche Modell, und bei einer einzigen Trainingstrajektorie ist das oft eines, das nur diese Trajektorie gut kann. Es ist dasselbe Trajektorien-Overfitting, das EvoGrow in C-1 zeigt.

Was es kostet

Das Rezept braucht pro Einheit im Median 6,4 % (dim 1), 3,2 % (dim 2) und 8,8 % (dim 3 fittbar) der Loss-Evaluationen, die EvoGrow C-1 für dieselbe Einheit braucht; gepoolt etwa 4 %. Fast alles davon fällt in diesem Schritt an, die schwache Form kostet dagegen praktisch nichts. Die Kosten sammeln sich bei den großen Kandidaten am Ende des Pfads, die oft das ganze Budget ausschöpfen, obwohl sie fast nie gewählt werden.

Fallstricke

WAS UNTER RAUSCHEN OFFEN IST

- **Der Boden verschwindet.** Unter Rauschen bestimmt das Rauschen den MSE, nicht der Integrator. Ob BIC dann noch die richtige Größe wählt oder ob jeder weitere Term ein bisschen Rauschen „erklärt“ und gewinnt, misst Q5.
- **N ist zu groß.** Die Abweichungen einer simulierten Trajektorie sind zeitlich stark korreliert: Liegt das Modell bei t_i daneben, liegt es bei t_{i+1} fast genauso daneben. N = 512 × Dimension überschätzt die Zahl unabhängiger Beobachtungen, und die Strafe log(N) ist entsprechend falsch skaliert.
- **Der Anfangswert.** Simuliert wird ab dem ersten Messpunkt. Unter Rauschen ist der selbst verrauscht, und der ganze Fit muss diesen falschen Start ausbaden. Für die Paper-Version ist festgelegt, den Anfangswert mitzuschätzen (Variante C). Q5 misst vorher, wie viel dieser Fehler ausmacht.
- **Viele Kandidaten.** AIC und BIC wählen bekanntermaßen zu große Modelle, wenn es im Verhältnis zur Datenmenge viele Kandidaten gibt (Gohain & Jansson 2023).
- **Chaos.** Bei chaotischen Systemen wie Lorenz laufen selbst richtige Modelle nach einiger Zeit auseinander. Dann misst der Trajektorien-MSE nicht mehr die Struktur. In Q5 betrifft das die ausgeschlossenen dim-3-Systeme.

- **Die Schranke.** Liegt ein wahrer Koeffizient außerhalb von [−10, 10], kann auch der richtige Kandidat nicht gut fitten. Darum werden die Systeme 54–59 getrennt berichtet.

Was man daraus mitnimmt

KURZ

Der Trajektorien-Check macht zwei Dinge. Er bringt jeden Kandidaten vom schwachen Startwert aus mit einem einzigen BFGS-Fit in die Form, die beim Simulieren zählt. Und er wählt per BIC die Größe. Er ist der Grund, warum Q4 gegen das schwache BIC so deutlich gewinnt. Seine Grenzen: Er kann nur wählen, was der Pfad liefert; auf sauberen Daten entscheidet am Boden Rundungsrauschen; und ob die BIC-Strafe unter Rauschen richtig sitzt, ist die eigentliche offene Frage von Q5. Hier liegt nach der Literaturprüfung auch der mögliche Beitrag: Die nächsten Arbeiten wählen entweder im Regressionsraum oder simulieren ohne nichtlinearen Refit.

Literatur

Aus dem Gedächtnis bzw. aus `docs/sideproject_residual_growth_literature.md`, noch nicht von einem Menschen gelesen. Mit (prüfen) markiert, wo die Angaben unsicher sind.

- Schwarz 1978, „Estimating the dimension of a model“, Ann. Statist. 6(2). Das BIC.
- Akaike 1974, „A new look at the statistical model identification“, IEEE Trans. Autom. Control 19(6). Das AIC.
- Burnham & Anderson 2002, Model Selection and Multimodel Inference, Springer. Standardwerk zu AIC und BIC in der Praxis.
- Mangan, Kutz, Brunton & Proctor 2017, „Model selection for dynamical systems via sparse regression and information criteria“, Proc. R. Soc. A 473. Der nächste Verwandte: Kandidaten simulieren, Auswahl per AIC.
- Piroddi & Spinelli 2003, Int. J. Control 76(17); Farina & Piroddi 2010, Int. J. Control 83(7). Auswahl per Simulationsfehler in der NARX-Linie.

- Gohain & Jansson 2023, IEEE Trans. Signal Process. AIC und BIC wählen bei vielen Kandidaten zu große Modelle.
- Bayón-Buján & Merino 2024, arXiv 2403.06809 (prüfen). Weak-SINDy-Auswahl mit anschließendem Refit in Integralform, die nächste Arbeit vom Typ „schwache Auswahl plus Refit“.